

LAPORAN UAS
MATA KULIAH DATA MINING



Disusun oleh:

Nama : Irfan Aziz Anggara
NIM : 241011402611
Kelas : 04TPLM008

PROGRAM STUDI TEKNIK INFORMATIKA
FAKULTAS TEKNIK
UNIVERSITAS PAMULANG
TAHUN 2025/2026

1. Pemilihan & Karakteristik Dataset


Untuk memenuhi kriteria tugas, proyek ini menggunakan Mall Customer Segmentation Dataset yang telah disisipkan cacat data artifisial (berupa missing values dan baris duplikat). Dataset ini merekam karakteristik pelanggan mal melalui beberapa atribut utama: ID Pelanggan, Usia, Pendapatan Tahunan (Annual Income dalam ribuan USD), dan Skor Pengeluaran (Spending Score dengan rentang 1-100). Fokus pengelompokan ditargetkan pada fitur numerik pendapatan dan tingkat pengeluaran konsumen.

2. Tahap Cleaning Data

- **Penanganan Data Duplikat:** Sistem mendeteksi adanya baris data yang berulang secara identik. Baris duplikat dieliminasi menggunakan fungsi deduping untuk mencegah bias pembobotan jarak pada penentuan pusat cluster (centroid).
- **Penanganan Missing Values:** Data yang hilang pada fitur numerik diisi menggunakan teknik Imputasi Median. Pendekatan ini dipilih karena nilai median lebih kokoh terhadap pengaruh penciran (outliers) dibandingkan nilai rata-rata (mean).
- **Standarisasi Data (Scaling):** Karena algoritma berbasis jarak seperti K-Means sangat sensitif terhadap skala metrik, dilakukan standarisasi menggunakan Z-Score sehingga seluruh fitur memiliki rata-rata $\mu = 0$ dan standar deviasi $\sigma = 1$.


3. Evaluasi dan Visualisasi

Penentuan jumlah kelompok (k) yang paling ideal dilakukan dengan mengombinasikan dua metode evaluasi kuantitatif:



- Elbow Method: Berdasarkan grafik Within-Cluster Sum of Squares (WCSS) di atas, penurunan nilai inersia mulai melandai secara signifikan (membentuk sudut siku) tepat pada titik $k = 5$.
- Silhouette Score Analysis: Nilai struktur kedekatan cluster (Silhouette) menunjukkan performa yang optimal pada area rentang cluster tersebut, memvalidasi bahwa pembagian data ke dalam 5 segmen memberikan batas pemisah kelompok yang paling jelas dan padat.

Menggunakan parameter optimal $k = 5$, algoritma K-Means dijalankan untuk mengelompokkan data pelanggan ke dalam ruang dimensi terstandarisasi. Hasil proyeksi visualisasi 2D antara fitur pendapatan tahunan dan skor pengeluaran menghasilkan pembagian area sebaran yang sangat terstruktur:



4. Kesimpulan

Dari hasil pengerjaan tugas UAS Data Mining ini, penerapan algoritma K-Means Clustering terbukti sukses mengelompokkan karakteristik pelanggan dengan baik. Proses awal seperti membersihkan data dari baris yang ganda dan mengisi nilai kosong menggunakan nilai median sangat membantu agar data menjadi siap pakai. Selain itu, mengubah skala data menggunakan StandardScaler juga penting supaya variabel pendapatan dan skor pengeluaran memiliki bobot seimbang saat dihitung jaraknya oleh algoritma.

Untuk menentukan jumlah kelompok yang paling pas, laporan ini menggunakan metode Elbow dan Silhouette Score. Pada grafik Elbow, penurunan garis mulai melandai dan membentuk pola siku yang jelas pada angka lima. Hasil ini juga diperkuat oleh skor Silhouette yang menunjukkan bahwa pembagian menjadi lima kelompok menghasilkan struktur klaster yang paling rapi dan terpisah. Oleh karena itu, jumlah lima cluster dipilih sebagai model final.

Hasil akhir dari pengelompokan ini berhasil membagi pelanggan mal menjadi lima tipe yang berbeda. Kelompok pertama adalah pelanggan hemat (pendapatan dan pengeluaran rendah), kelompok kedua adalah pelanggan target utama atau "sultan" (pendapatan dan pengeluaran tinggi), kelompok ketiga adalah pelanggan impulsif (pendapatan rendah tapi pengeluaran tinggi), kelompok keempat adalah pelanggan bijak (pendapatan tinggi tapi pengeluaran rendah), dan kelompok terakhir adalah pelanggan standar yang berada di kelas menengah untuk kedua variabel tersebut.